1. Visão Geral

Os testes foram executados a partir de 1743 perguntas enviadas ao chatbot. Essas perguntas foram criadas a partir da base de conhecimento. Dentre as perguntas geradas, temos:

- Perguntas originais da base de conhecimento.
- Perguntas sintéticas formuladas a partir das perguntas originais com variações lexicais, mantendo a semântica e a resposta esperada.
- Perguntas com erros de digitação propositais.
- Perguntas indiretas (Sem sinal de interrogação, por exemplo ("Me explique para que serve a vacina de HPV).
- Perguntas com linguagem coloquial e abreviações de internet (Ex: O q fazer quando a vacina dá reação?).

Dentre as métricas utilizadas para os testes automatizados está a exatidão factual (Factual Correctness/Factuality), utilizada para avaliar a veracidade das informações presentes na resposta obtida, comparando-a com a resposta esperada. Os testes foram executados no dia 04 de abril de 2026.

2. Resultados

A Tabela 1 apresenta o desempenho da métrica de Factual Correctness (F1) segmentada por categorias, onde o volume de testes realizados é indicado pela coluna de contagem (n), totalizando 1743 avaliações no cenário geral. Os resultados são distribuídos em intervalos de pontuação que variam de 0.0 a 1.0, nos quais as porcentagens em cada coluna refletem a proporção de testes que obtiveram aquele desempenho específico.

Tabela 1 - Score de corretude factual considerando todos os testes

Score de Corretude Factual	Porcentagem de Testes	Quantidade de Testes
0	9,1%	160
0 à 0,1	0,5%	9
0,1 à 0,2	2,9%	52
0,2 à 0,3	4,6%	81
0,3 à 0,4	4,7%	83

0,4 à 0,5	6,0%	105
0,5 à 0,6	10,8%	189
0,6 à 0,7	14,9%	261
0,7 à 0,8	12,3%	215
0,8 à 0,9	16,1%	282
0,9 à 1	17,5%	306

Ao analisar a distribuição, observa-se que a maior concentração de resultados encontra-se nas faixas de pontuação mais altas, especificamente no intervalo de 0,9 à 1, que lidera com 17,5% (306 testes), seguido de perto pela faixa de 0,8 à 0,9 com 16,1% (282 testes). Somando-se os intervalos acima de 0,7, percebe-se que quase metade da amostra (45,9%) demonstra uma alta precisão factual. Por outro lado, nota-se um ponto de atenção no extremo inferior: embora os intervalos intermediários de erro (0,1 a 0,5) apresentem frequências baixas, a pontuação exata de 0 registra um volume significativo de 9,1% (160 testes). Em suma, os dados revelam uma tendência de concentração à direita, sugerindo que o sistema atinge um nível de corretude satisfatório na maioria das interações, apesar de manter um resíduo relevante de erros absolutos.

É fundamental que esses resultados sejam confirmados por meio de uma avaliação humana criteriosa, uma vez que as respostas do chatbot apresentam um comportamento bastante verboso, o que pode impactar negativamente a métrica automatizada; em diversos casos, o excesso de texto acaba gerando scores baixos mesmo quando as informações centrais estão corretas, evidenciando uma possível penalização pela forma da resposta e não necessariamente pelo seu conteúdo factual.

A Tabela 2 apresenta as pontuações acumuladas obtidas nos testes considerando a métrica de corretude factual.

Tabela 2 - Score de corretude factual acumulado

Score de Corretude Factual Acumulado	**Porcentagem de Testes**	**Quantidade de Testes**
>0	90,8%	1583
>0,1	90,1%	1571
>0,2	86,8%	1514
>0,3	82,5%	1438

>0,4	75,9%	1324
>0,5	68,3%	1191
>0,6	58,8%	1026
>0,7	45,3%	791
>0,8	28,8%	502
>0,9	16,7%	292

A Tabela 2 detalha o score de corretude factual acumulado, revelando que a grande maioria das interações apresenta algum grau de acerto, com 90,8% dos testes obtendo uma pontuação superior a 0. Conforme os critérios de exigência aumentam, observa-se que 68,3% da amostra consegue manter um desempenho acima de 0,5, indicando uma consistência moderada na precisão das respostas. Entretanto, o volume de testes com excelência factual é mais restrito, visto que apenas 16,7% das respostas atingem um score superior a 0,9. Essa redução gradual nos percentuais acumulados sugere que, embora o sistema raramente apresente falhas críticas, encontra-se dificuldade em alcançar a pontuação máxima. Esse cenário reforça a hipótese de que a verbosidade do chatbot pode estar diluindo a métrica, resultando em pontuações parciais mesmo quando as informações estão presentes, o que torna a avaliação humana indispensável para validar se as notas mais baixas refletem erros factuais reais ou apenas um estilo de redação excessivamente detalhado.

A Tabela 3 apresenta o score de corretude factual segmentado por temas, revelando disparidades significativas no desempenho do chatbot dependendo do assunto abordado. Foram selecionados os temas com média de score inferior ou igual a 0,5.

Tabela 3 - Score de corretude factual dos testes categorizados por tema

Tema	Média de correção factual	Quantidade de testes	Porcentagem de score = 0	Porcentagem de score entre 0 e 0,1	Porcentagem de score entre 0,1 e 0,2	Porcentagem de testes com score > 0,3
VSR - Acesso e Documentação	0,1	9	55,6%	0%	33,3%	11,1%
VSR - Proteção e Eficácia	0,2	19	42,1%	0%	10,5%	47,4%
Denúncias,	0,5	17	27,4%	0%	0%	72,6%

Reclamações e Segurança						
Dispensação por Terceiros	0,5	17	28,8%	0%	0%	71,2%
Fraldas geriátricas	0,4	52	28,8%	1%	4%	66,2%
Regras para Prescrições e Receituários	0,5	50	14%	0%	0%	86%
VSR - Contraindicações e Segurança	0,4	17	23,5%	0%	11,8%	64,7%
Vacina VSR Gestante	0,4	58	19%	0%	3,4%	77,6%
Vacina inativada poliomielite (VIP)	0,5	45	26,7%	0%	2,2%	71,1%
Vacina pneumocócica 20 -valente (conjugada) VPC20)	0,5	31	35,5%	0%	0%	64,5%
Vacina vírus sincicial respiratório (VSR)	0,4	25	36%	0%	0%	64%

Considerando apenas os temas com média de score inferior ou igual a 0,5, observa-se que temas relacionados a Regras para Prescrições e Receituários apresentam os melhores indicadores. Nesse caso, 86% dos testes com esse tema superou o score de 0,3 de corretude factual. Por outro lado, as categorias ligadas ao VSR, especialmente em Acesso e Documentação, demonstram fragilidades acentuadas, registrando uma média de correção factual de apenas 0,1 e mais da metade dos testes com score zero. Embora a maioria dos temas mantenha uma média de correção factual entre 0,4 e 0,5, a presença constante de respostas com pontuação zero em todas as categorias reforça a necessidade de validação humana, pois a verbosidade do modelo pode estar influenciando negativamente esses índices.

3. Análise dos Resultados

A Figura 1 apresenta um gráfico de barras de Corretude Factual que ilustra visualmente a distribuição mencionada anteriormente na Tabela 1, reforçando a tendência de crescimento do volume de interações à medida que o score de precisão aumenta. Fica evidente que as colunas mais expressivas estão concentradas à direita, com o patamar superior a 90% atingindo o ápice de 17,55% das interações, seguido por uma performance robusta nas faixas de 80% e 70%. Por outro lado, a representação visual também destaca o "degrau" crítico no extremo esquerdo, onde a pontuação de 0% isolada detém 9,17% das ocorrências, um volume significativamente maior do que as faixas imediatamente posteriores.

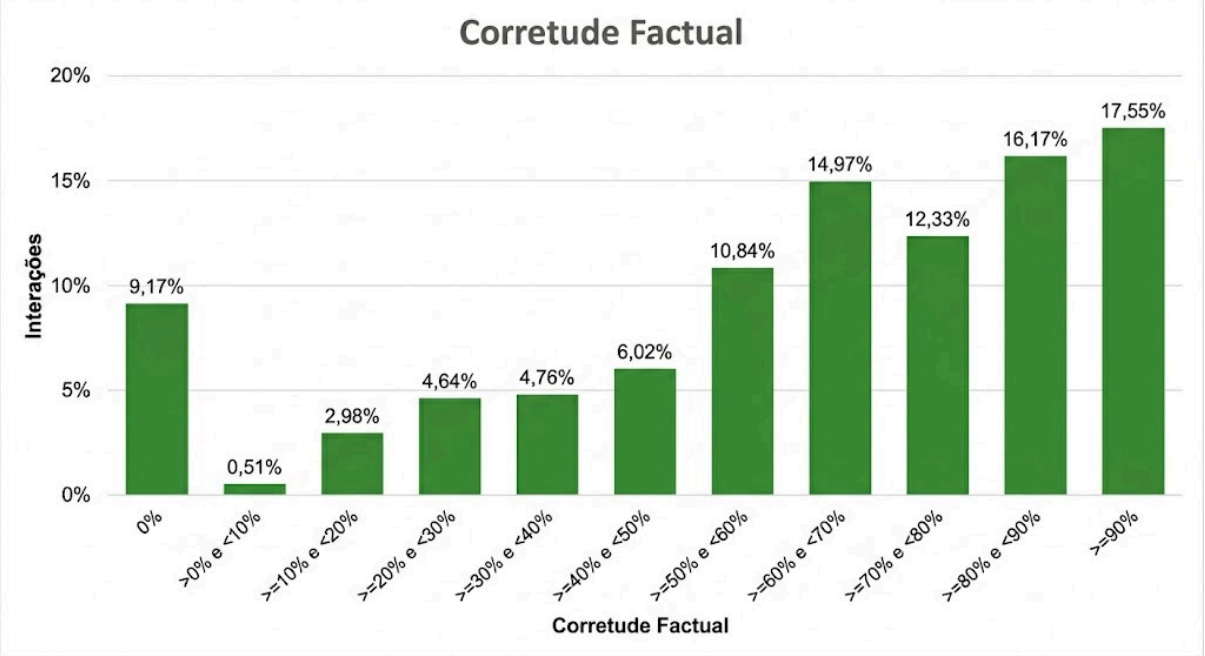

O gráfico de Corretude Factual Acumulado da Figura 2 complementa essa visão ao demonstrar a resiliência do sistema em manter um nível mínimo de precisão em grande parte das interações. É possível observar que 90,82% de todos os testes realizados superam o score zero, o que indica que a vasta maioria das respostas contém, ao menos, algum conteúdo correto. No entanto, o gráfico exibe uma queda gradual e constante conforme o nível de exigência de corretude aumenta, chegando a 16,75% de interações que conseguem ultrapassar o patamar de 90%.

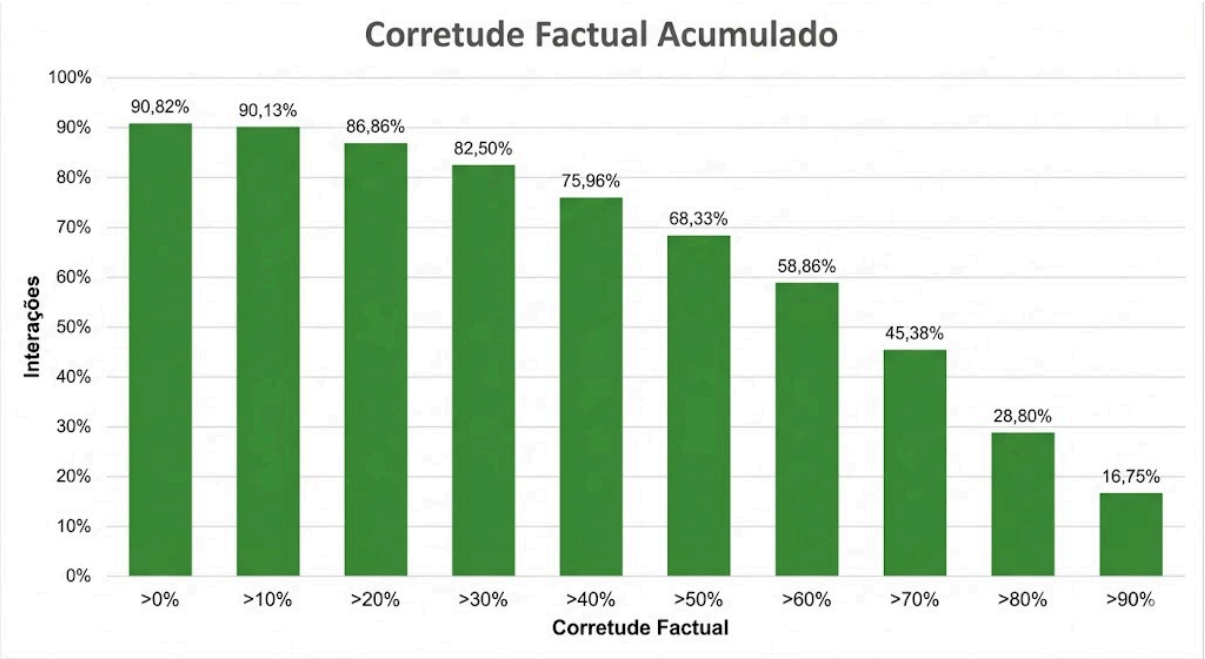

Considerando que dentre os 1743 testes foram incluídos intencionalmente perguntas com variações lexicais, erros de digitação, linguagem indireta e abreviações coloquiais, é possível refletir a variabilidade da interação real do usuário.

A taxa de corretude factual revela desafios na precisão das respostas. No cenário geral, ao observar a distribuição acumulada, 41,14% dos testes (correspondendo a 717 avaliações, conforme os dados de score acumulado) registraram um desempenho de correção factual inferior ou igual a 0,3.

Oportunidades de Otimização por Tema

As maiores oportunidades de melhoria concentram-se em temas específicos com baixo desempenho médio de score:

- VSR - Acesso e Documentação e VSR - Proteção e Eficácia demonstraram as médias de score mais baixas (0,1 e 0,2, respectivamente).
- Na categoria "VSR - Acesso e Documentação", mais da metade dos testes (55,6%) resultou em zero acerto factual, e apenas 11,1% dos testes alcançaram um score superior a 0,3.
- Outros temas, como Fraldas Geriátricas e Vacina VSR Gestante, também ficaram abaixo da média geral (com scores médios de 0,4).